#### بسم الله الرحمن الرحيم



دانشگاه صنعتی شریف دانشکددی مهندسی کامپیوتر

## پردازش زبان طبیعی نیمسال اول ۱-۰۲۰ مدرس: احسان الدین عسگری

## تمرین چهارم طبقهبندی متن طبقهبندی توکن ـ تولید متن مهلت ارسال: ۱۵ بهمن

- مهلت ارسال پاسخ تا ساعت ۲۳:۵۹ روز مشخص شده است.
- در تمرینهایی که چند ترک دارند، فقط یک نفر از هر گروه در سامانه CW باید ترک مورد نظر گروه را انتخاب کند. امکان تغییر ترک تا قبل از زمان ددلاین انتخاب ترک وجود دارد. البته ذکر این نکته ضروری است که هر ترک محدودیتی برای تعداد افرادی که آن را انتخاب میکنند، دارد. بنابرین در اسرع وقت برای انتخاب ترک اقدام کنید.
- در طول ترم امکان ارسال با تاخیر تمرینها بدون کسر نمره تا سقف ۱۲ روز وجود دارد. محل بارگزاری جواب تمرینها بعد از ۳ روز بسته خواهد شد. همچنین، به ازای هر روز تأخیر غیر مجاز ۱۵ درصد از نمره تمرین کسر خواهد شد.
- توجه داشتهباشید که نوتبوکهای شما باید قابلیت بازاجرای ۱۰۰ درصد داشته باشند و در صورت نیاز به نصب یک کتابخانه یا دسترسی به یک فایل، مراحل نصب و دانلود (از یک محل عمومی) در نوتبوک وجود داشته باشد.
- تمامی فایلهای مرتبط به پروژه که حجم کمی دارند باید به شکل فایل زیپ در سامانه CW اپلود شوند. اگر حجم یک فایل زیاد بود (مانند فایل ذخیره شده یک مدل در صورتیکه بیش از ۲۰۰ مگابایت باشد)، تنها همان فایل را در یک محل عمومی، مثل گوگل درایو آپلود بفرمایید و لینک دانلود را در نوتبوک و مستندات قرار دهید.
- در پروژههای گروهی کافی است که فقط یکی از اعضای گروه پروژه را آپلود کند. اما حتما در گزارش کار نام همه اعضای گروه همراه با شماره دانشجویی آنها آورده شود.
- بخشی از نمره شما به گزارش کار شما اختصاص دارد. در گزارش کار لازم نیست خط به خط کاری را که کردهاید توضیح دهید. بلکه باید به شکل کلی ایده تان برای حل مساله را شرح دهید. لازم است چند نمونه از خروجیهای مساله را در گزارش بیاورید و براساس آن رفتار برنامه تان را تحلیل کنید. همچنین اگر پارامتری در صورت مساله خواسته شده (مانند دقت، صحت و ...) که در گزارش آورده شود شما باید آن را حساب کنید و در گزارش خود بیاورید.
- در صورت وجود هرگونه ابهام یا مشکل، در کوئرای درس آن مشکل را بیان کنید و از پیغام دادن مستقیم به دستیاران آموزشی خودداری کنید.

## سازوكار تمرين

در این تمرین هر گروه یکی از شش موضوع پیشنهادی را انتخاب خواهد کرد. هر موضوع شامل سه بخش طبقهبندی متن، طبقهبندی توکن و تولید متن است. هر تیم موظف است دو بخش از سه بخش موضوع انتخابی را برای انجام انتخاب کند. در برخی از موضوعات یک بخش شامل چند زیربخش است، در چنین مواردی انجام یکی از زیربخشها برای کسب نمره کامل آن بخش کافی است. انجام دادن بخش سوم علاوه بر دو بخش انتخابی، دارای نمره امتیازی میباشد که فقط کسر نمره در همین تمرین را جبران میکند.

در بخش طبقهبندی لازم است برای موضوع پیشنهادی سه مدل زیر را پیادهسازی کنید:

- ۱. مدل رگرسیون لجستیک ۱ با استفاده از بردار ویژگی tf-idf
- ۲. شبکه عصبی با استفاده از بردار ویژگی fasttext (با استفاده از tf-idf به شکل وزندار بردارهای fasttext را میانگین بگیرید)
  - ۳. استفاده از طبقهبندهای بر پایه ترنسفورمر (به عنوان مثال تنظیم کردن<sup>۲</sup> پارامترهای برت)

برای ارزیابی تمام قسمتها به جز رگرسیون لجستیک دادگان خود را به نسبت ۸۰ به ۲۰ به دو قسمت آموزش و ارزیابی تقسیم کنید و برای رگرسیون لجستیک از Cross validation استفاده کنید و معیارها را در این حالت به شکل میانگین و انحراف معیار گزارش کنید. برای بخشهای طبقهبندی معیارهای Precision ،Recall ،Accuracy و Bert-Score و Bleu-{۱،۲،۳،۴} و برای بخشهای تولید متن معیارهای F1 Score(micro/macro) و برای بخشهای تولید متن معیارهای گزارش کنید و اگر معیار دیگری لازم بود در خود ترک گفته شده است. همچنین ماتریکس درهمریختگی برای بخش طبقهبندی متن رسم گردد.

مدلهای آموزش داده شده خود را داخل درایو ذخیره کنید و با gdown از آنها استفاده کنید.

در نهایت، یک تابع برای گرفتن خروجی مدلها به ازای ورودی مشخص بنویسید.

<sup>&</sup>lt;sup>1</sup>Logistic Regression

<sup>&</sup>lt;sup>2</sup>Fine-tune

<sup>&</sup>lt;sup>3</sup>Confusion Matrix

# اخبار

#### طبقهبندي متن

#### طبقهبندي موضوع خبر

در این بخش به پیدا کردن موضوع خبر از یک متن خبر پرداخته می شود. برای دادگان این بخش مجموعه دادگان اخبار آزمایشگاه در اختیار شما قرار می گیرد و شما باید مدلی پیاده سازی کنید که با گرفتن یک خبر دسته آن خبر را بگوید به عنوان مثال بگوید که خبر ورزشی یا سیاسی یا .. است.

## طبقهبندى توكن

پرسش و پاسخ در این ترک از حل مساله پرسش و پاسخ استخراجی<sup>۴</sup> است. بدین منظور به شما مجموعه دادهای داده می شود و هدف آموزش یک مدل پرسش و پاسخ استخراجی برروی این مجموعه داده است. پرسش و پاسخ استخراجی بدین معناست که سندی<sup>۵</sup> که اط آن پرسش می شود مشخص است و تنها هدف پیدا کردن بازه پاسخ از سند است.

پرسش و پاسخ یک مساله طبقهبندی توکن ٔ است چراکه با دادن یک پرسش هدف پیدا کردن توکن ابتدا و انتهای پاسخ از سند موردنظر است.

برای دانلود مجموعه دادگان به این لینک مراجعه کنید.

بدین منظور شما باید یک مدل پرسش و پاسخ را بر روی مجموعه دادگان آموزش دهید و امتیاز  $^{\dagger}$ 1 و  $^{\dagger}$ 2 را برروی داده تست گزارش دهید. امتیاز  $^{\dagger}$ 1 برای مسئله پرسش و پاسخ میزان همپوشانی پاسخ مرجع با پاسخ تولید شده است.

به موراد زیر نیز توجه کنید:

- شبکهی پرسش و پاسخ باید بهدرستی آموزش داده شده باشد و آموزش درست و انتخاب صحیح ابرپارامترها در نمرهدهی تاثیر مستقیم دارد
- نمره اضافی: در صورت تحلیل دقیق خطای مدل به شما نمره اضافی تعلق میگیرد. برای اینکار یک پرسش را از داده اعتبارسنجی به دلخواه انتخاب کنید و مطابق با آموزش این لینک مقدار تاثیر هر توکن در ورودی بر پاسخ را بررسی کنید (برای مثال با الگوریتم Gradient)

  (Integrated

توجه: در هرکدام از زیربخشهای تولید متن در صورت طولانی شدن زمان آموزش میتوانید با اعلام این موضوع از زیرمجموعهای از داده استفاده کنید.

## توليد متن

تولید پرسش از متن تولید دادگان پرسش و پاسخ معمولا دارای هزینه انسانی و زمانی بالایی است. از اینرو در این زیربخش سعی در ایجاد پرسش و پاسخهای بیشتر و افزایش<sup>^</sup> مجموعه دادگان خود کنیم. تولید پرسش و پاسخ نه تنها در افزایش مجموعه دادگان بلکه کاربردهایی مانند ایجاد پرسش

<sup>&</sup>lt;sup>4</sup>Extractive Question Answering

<sup>&</sup>lt;sup>5</sup>Document

<sup>&</sup>lt;sup>6</sup>Token

<sup>&</sup>lt;sup>7</sup>Exact Matching

<sup>&</sup>lt;sup>8</sup>Augment

برای آموزش هم دارد.

برای دانلود مجموعه دادگان به این لینک مراجعه کنید.

برای اینکار شما از یک مجموعه دادگان پرسش و پاسخ استفاده کرده و مدلی را آموزش خواهید داد تا با استفاده از آن بتوان از متن ورودی تعداد پرسش به همراه پاسخشان ایجاد کرد. بدین منظور دو کار شما دارای سه مرحله خواهد بود:

- ۱. در مرحله نخست ابتدا باید یک شبکه مولد<sup>۹</sup> را برای تولید پرسش آموزش دهید. برای اینکار از مجموعه داده آموزشی استفاده میکنید بدین شکل که پاسخ و سند<sup>۱۱</sup> به عنوان ورودی شبکه داده شده و برچسبها نیز همان پرسشها هستند
- ۲. در مرحلهی دوم باید پس از آموزش شبکه، برروی داده اعتبارسنجی معیارهای گفته شده در تمرین را محاسبه کنید
- ۳. در مرحله سوم نوبت به تولید پرسشهای خودتان میرسد. بدین منظور برای تولید یک جفت پرسش و پاسخ، ابتدا باید یک پاسخ از متن استخراج کرده و به همراه سند به شبکه آموزش داده مولد داده تا پرسش نیز ایجاد گردد. برای تولید پاسخ در این مرحله می توانید از مباحث گذشته درس استفاده کرده و برای مثال یکی از موجودیتهای نامدار یا صفات یا عبارات نامدار ۱۱ ها را به عنوان پاسخ در نظر بگیرید. واضحا برای انتخاب پاسخ، راه حلهای زیادی وجود دارد.

## به موراد زیر نیز توجه کنید:

- شبکهی مولد باید به درستی آموزش داده شده باشد و آموزش درست و انتخاب صحیح ابرپارامترها
   در نمره دهی تاثیر مستقیم دارد
- برای انجام مرحله سوم ترک باید از سه متن مختلف، ده جفت پرسش و پاسخ از هرکدام تولید کنید
- نمره اضافی: تنظیم دقیق پارامترهای تولید متن برای ایجاد پرسشهای متنوعتر و جالبتر نسبت به حالت عادی نمره اضافی در پی خواهد داشت. برای آگاهی از این پارامترهای مختلف در تولید متن به این لینک مراجعه کنید

#### خلاصهسازي

خلاصه کردن متن یک کار مهم در پردازش زبان طبیعی است، زیرا امکان استفاده ی کارآمد از مقادیر زیادی از متن را با فشرده کردن آن به شکل کوتاه و مختصر تر فراهم میکند. در این تکلیف، شما از مدل های زبانی برای خلاصه کردن یک متن استفاده می کنید. وظیفه شما پیاده سازی سیستمی خواهد بود که بتواند بطور خودکار خلاصه ای از متن را ایجاد کند که ایده های اصلی و اطلاعات کلیدی خود را حفظ کند. برای این کار از دادگان خلاصه ی خبر فارسی لینک طبق آنچه در ادامه بیان می شود استفاده می کنیم:

<sup>&</sup>lt;sup>9</sup>Generative

<sup>&</sup>lt;sup>10</sup>Document

<sup>&</sup>lt;sup>11</sup>Noun Phrase

- در این مرحله از شما خواسته شده است شبکه ی مولدی<sup>۱۲</sup> را جهت خلاصه سازی متن ورودی آموزش دهید.
- ۲. در این مرحله شما باید عملکرد مدل را بر روی جفت متن و خلاصه هایی که خودتان از پیش
   آماده کرده اید بررسی کنید.

# به موارد زیر نیز توجه کنید:

- شبکهی مولد باید بهدرستی آموزش داده شده باشد و آموزش درست و انتخاب صحیح ابرپارامترها در نمره دهی تاثیر مستقیم دارد.
  - برای انجام مرحله سوم ترک باید از ۵ جفت متن و خلاصه استفاده کنید.
  - نمره اضافی: افزایش تعداد نمونه های مرحله ی ۳ به ۱۰ نمونه، نمره ی اضافی دارد.

<sup>&</sup>lt;sup>12</sup>Generative

## گونهی محاورهای در مقابل گونهی رسمی

طبقهبندی متن هدف این بخش تشخیص گونهی محاورهای از رسمی در زبان فارسی است. شما باید مدلی

پیاده سازی کنید که با دریافت یک جمله از ورودی، محاوره ای یا رسمی بودن آن را تشخیص دهد. همچنین کلمات کلیدی هر کلاس را که بیشترین تاثیر را داشته اند مشخص کنید.

طبقهبندی توکن هدف این بخش طبقهبندی توکنهای موجود بر اساس محاوره، رسمی و خنثی بودن کلمات در

متون است. به این معنا که باید مدلی آماده کنید تا بتواند موجودیتهای محاورهای، رسمی و خنثی را تشخیص دهد. خنثی به این معنی است که کلمه قابل شکستن نیست و تفاوتی در صورت محاورهای و رسمی آن وجود ندارد. **تولید متن** هدف این بخش پیادهسازی مدلی است که قابلیت تبدیل گونهی محاورهای به رسمی را داشته باشد. مدل

پیادهسازی شده با دریافت یک جمله از ورودی، باید جملهی رسمی معادل آن را تولید کند.

مجموعه دادگان مجموعه دادگانی از جملات محاورهای و معادل رسمی آنها تولید شده و برای بخش اول و سوم

در اختیار شما قرار میگیرد. برای بخش دوم لازم است تعدادی جمله را برچسبگذاری کنید. بدین منظور از سه حرف  $^{17}$ ،  $^{17}$  و  $^{16}$  استفاده نمایید که به ترتیب نشاندهندهی رسمی، محاورهای و خنثی بودن کلمه است. یک نمونه از این کار در جدول زیر برای جملهی «دارم میرم خانه» آمده است:

برچسب	توكن
N	دارم
С	ميرم
F	خانه

Formal<sup>\\\\</sup>

Colloquial 15

Neutral 16

#### نظرات فيلم

#### طبقهبندي متن

هدف از این بخش دسته بندی ریزدانه احساسات در دیتاست ۵-SST به پنج کلاس است. این دیتاست جز دیتاستهای پایه برای ارزیابی وظیفه دسته بندی متن است که در تابلوی امتیازات می توانید تلاشهای صورت گرفته را مشاهده کنید. هدف از این تمرین پیاده سازی مدلی جهت دسته بندی است و نیاز به صرف زمانی طولانی برای آموزش مدل و رسیدن به دقی های تابلوی امتیازات نیست. در نهایت کلمات کلیدی از هر کلاس را مشخص کنید.

#### طبقەبندى توكن

شناسایی موجودیتهای نامدار زیرمجموعه مسائل استخراج اطلاعات است که به دنبال مکانیابی و طبقهبندی موجودیت های نامدار در متن به دسته های از پیش تعریف شده نظیر نام افراد، سازمان ها، مکان ها و غیره است. در این بخش هدف ما طبقه بندی موجودیتهای نامدار دیدگاههای موجود در imdb بر اساس دستهبندی بازیگر، کارگردان، ژانر، میانگین نمره، آهنگ، موضوع، سال، شخصیت داستانی، پلات، دیدگاه، پیش نمایش است. برای این کار شما میتوانید از دادههای دانشگاه MIT استفاده کنید. مدل شما باید با ورودی گرفتن یک جمله به ازای هر کلمه دسته بندی آنرا مشخص کند.

#### توليد متن

هر چند مدلهای زبانی قادر به تولید متن شبیه به انسان هستند، اما کنترل ویژگیهای متن تولیدشده هنوز یکی از چالشهای روز پردازش زبان طبیعی به شمار می رود. در این بخش شما باید با استفاده از یک مدل زبانی مثالهایی برای افزایش اندازه مجموعه دادگان ۵-SST تولید کنید. هدف از این تمرین تولید دادههای تحلیل احساس در ۵ کلاس است و لزومی به ایجاد ساختار درختی در دادههای تولیدی همانند ۵-SST نیست. در این تمرین شما باید با استفاده از مدلی نظیر GPT جملاتی با دسته احساس مشخص تولید کنید. از جملات تولیدشده برای تنظیم دقیق مدل بخش طبقهبندی متن استفاده کرده و نتایج را گزارش دهید. هر چند روش حل این تمرین کاملا به انتخاب شماست و شما محدود به استفاده از روش مشخصی نیستید اما برای شروع سری به کد و مقاله GeDi بزنید. مدل GeDi رویکری مبتنی بر قانون بیز برای تولید متن بر اساس کلاسهای مشخص ارائه می دهد. GeDi امکان تولید متن برای دو کلاس postive بیز برای تولید متن در اینجا به آنها اشاره شده است، نیز حریصانه صورت می گیرد. خوب است که برای تولید متن از سایر روشها که در اینجا به آنها اشاره شده است، نیز استفاده کنید. ارزیابی این بخش باید بر اساس ۱) تحلیل کیفیت متنهای تولید شده به همراه ۲) بررسی اثر استفاده از دادههای تولید شده در تنظیم دقیق مدل طبقهبندی بخش اول تمرین انجام شود.

#### دادههای کلینیکال

#### مجموعه دادگان

مجموعه دادگانی که میتوانید در این ترک از آنها استفاده کنید دادگان ترکهای ۱ و ۲ چالش n2c2 سال ۲۰۱۸ هستند که از این لینک قابل دسترسیاند. توجه داشته باشید که برای دسترسی به این دادگان نیاز به ثبت درخواست در لینک فوق دارید. پس این مورد را نیز در زمان بندی خود لحاظ کنید. دادگان ترک ۱ برای طبقه بندی و دادگان ترک ۲ برای تولید متن و طبقه بندی توکن قابل استفاده هستند.

در این قسمت لازم است دو مورد از سه مورد ذیل را به انتخاب خود انجام دهید.

### طبقهبندي متن

هدف پیادهسازی یک مدل برای استخراج اطلاعاتی راجع به بیمار است. این دادگان براساس شرح حال ۲۰۲ بیمار بوده و شامل ۱۳ برچسب هستند که میتوانند دومقدار met و not met داشته باشند. مدل شما باید بتواند با توجه به شرح حال بیمار، مواردی که در زیر فهرست شدهاند را تشخیص دهد.

- ABDOMINAL
- CREATININE
- MAJOR-DIABETES

#### طبقەبندى توكن

در این بخش باید مدلی پیادهسازی کنید که با دریافت مشخصات بیمار و نسخهی او در ورودی، موجودیت های زیر را تشخیص دهد.

• Drug

Dosage

• Route

Strength

• Duration

• ADE

• Form

Frequency

Reason

## توليد متن

در این بخش باید مدلی پیادهسازی کنید که بر اساس اطلاعات هر بیمار، خلاصهای از شرح حال بیمارستانی ۱۶ او را تولید کند. این خلاصه در اطلاعات هر بیمار موجود است.

Brief Hospital Course 19

## زبان توهينآميز

## طبقهبندی متن

در این بخش، شما میبایست با استفاده از مجموعه دادگان OLID که شامل مجموعهای از متون و برچسبهای متناظر با آنهاست، مدل دسته بندی آموزش دهید که بتواند جملات را به دو دسته «توهین آمیز» و «غیرتوهین آمیز» طبقهبندی کند (همان سطح  $A^{1}$  در دیتاست OLID):

"OFF", "NOT"

### طبقهبندي توكن

در این بخش، شما میبایست در ابتدا با استفاده از مجموعه داده Toxic Spans (توضیح بیشتر مجموعه داده در این probability (یک دیتاست برچسبگذاری شده در سطح توکن بسازید. برای اینکار، توکن هایی که در ستون که در ستون امتیاز را دارد. ذکر شدهاند و امتیازشان بیشتر از ۵.۰ است را برچسبی همنام با گونهای در ستون type بزنید که بیشترین امتیاز را دارد. سایر توکنها را برچسب none بزنید.

سپس با استفاده از مجموعهداده تولید شده، مدلی آموزش دهید تا بتواند به ازای هر توکن ورودی، یکی از لیبلهای type دیتاست Toxic Spans یا none را برچسب بزند:

"insult", "threat", "identity-based attack", "profane/obscene", "other toxicity", "none"

#### توليد متن

در این بخش، شما باید با استفاده از مجموعه داده ParaDetox (توضیح بیشتر در این لینک)، مدل Seq ۲ Seq بر مبنای مبدل آموزش دهید که با دریافت یک جمله توهین آمیز در ورودی، معادل غیرتوهین آمیز آن را در خروجی تولید کند. برای این منظور از تمام معادل هایی که برای هر یک از نمونه ها در مجموعه داده ParaDetox در ستونهای تا neutral وجود دارد برای آموزش مدل استفاده کنید.

<sup>&</sup>lt;sup>17</sup>Level

#### كالا

در این تمرین قصد داریم روی دادگان دیجی کالا کار کنیم. این دادگان شامل پنج فایل است که از بین آنها، از فایل keifiat.xlsx و در صورت نیاز، product.xlsx استفاده خواهیم کرد.

### طبقهبندي متن

در بخش اول هدف دستهبندی نظرات کاربران بر اساس توصیه کردن محصول است. برای این منظور سه کلاس خواهیم داشت:

- recommended: يعنى نظر داده شده مثبت بوده و خريد كالا را پيشنهاد ميكند.
- not\_recommended: يعنى نظر كاربر منفى است و خريد كالا را پيشنهاد نمىكند.
- no\_idea: یعنی نظر کاربر در راستای پیشنهاد کالا خنثی است. مثلا ممکن است به نکات مثبت و منفی کالا به طور همزمان اشاره شده باشد.

برای پیادهسازی دستهبند این قسمت میتوانید از دادگان دو ستون comment و rec-فایل keifiat.xlsx استفاده کنید. در نظر داشتهباشید که دادههایی را استفاده کنید که ستون commend برای آنها خالی نباشد.

## طبقەبندى توكن

در این بخش به استخراج ویژگیهای محصول از نظرات کاربران خواهیم پرداخت. هدف این است که به ازای هر کامنت، توکنهای توصیفکننده ی ویژگی را با یک تگ جدید مشخص کنید. برای این کار لازم است تعدادی داده ی دارای برچسب تولید کنید و آموزش و ارزیابی را با استفاده از آنها انجام دهید. بدین منظور میتوانید تعدادی از نظرات کاربران را از فایل keifiat.xlsx انتخاب کنید (حدود ۲۰۰ الی ۳۰۰ نظر) و بصورت دستی توکنهای آنها را برچسب بزنید. سپس از این تعداد، بخشی را برای آموزش مدل استفاده کنید.

می توانید برای تولید برچسب از روشهای خلاقانه تری نیز استفاده کنید و بصورت تماما یا نیمه خود کار برچسبها را تولید کنید. ایده ی شما برای این کار چیست؟ برای این منظور، می توانید از فایل product.xlsx نیز استفاده کنید. توجه کنید که یکی از دو روش نیز برای برچسبزنی کافی است و اجباری برای انجام هر دو مورد وجود ندارد.

## توليد متن

در این بخش هدف تولید عنوان یک نظر براساس متن آن نظر میباشد. برای دادگان این بخش باید از فایل keifiat.xlsx و comment استفاده کنید. برای این قسمت باید یک مدل مولد پیادهسازی کنید که با استفاده از ستون comment ستون title را تولید کند.